시각화 자료 · 금융 문서 RAG 미니 프로젝트 · 2026-10-22

금융 문서 질의응답 시스템

금융 PDF 23개를 검색해, 찾은 근거만 보고 한국어로 답하고 출처(파일·쪽)를 붙이는 시스템입니다.

최종 시스템은 T4입니다. 질문이 오면 ① 후보 15개를 찾고 ② 작은 AI가 5개를 고르고 ③ 그 5개만 보고 답합니다. Agent가 아니라 3칸짜리 RAG입니다.

시험 131문항 점수 **0.855** (처음 시스템 0.718) · 질문당 **0.0036달러** · 평균 **2.8초**. 큰 AI 판(T2, 0.889)보다 0.03 낮지만 운의 범위 안이고, 비용은 40%, 속도는 2배라서 골랐습니다.

이 자료에 나오는 이름	무엇인가	나오는 곳
T4 최종	**제출하는 시스템. 3칸 RAG, 작은 AI (`configs/013b-rerank-lite.yaml`)**	**구조 · 점수 과정 · 시험 결과**
T1 · T2	비교용. T1은 처음 만든 RAG, T2는 T4와 같은 구조에 큰 AI	시험 결과
T3 Agent	비교용. 과제의 "기본 RAG 대 Agent" 비교를 위해 T2에 판단하는 칸을 더한 것	기본 RAG 대 Agent
Agent v2	시험 뒤에 해 본 개선 시도. 효과가 없어 버림	해 봤지만 효과가 없던 것

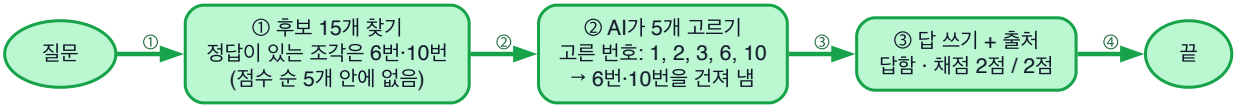
T4 최종 최종 시스템의 구조

질문이 올 때마다 하는 일 (3칸)



질문당 AI 호출 2번, 문서 찾기 1번. 다시 찾거나 스스로 검사하는 칸은 없습니다.

실제로 지나간 길 (연습 문제 POS061)

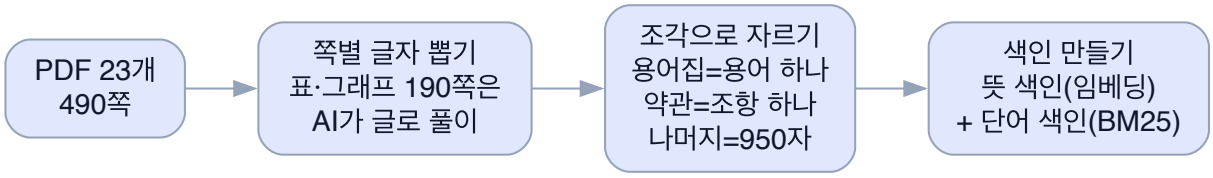


질문: "첫 월급을 받았는데 목표가 그냥 '돈 많이 모으기'예요. 가이드북에서는 이런 목표를 어떻게 바꾸라고 하나요?" 정답이 있는 쪽(20대 금융생활 가이드북 p.10)의 조각은 검색 점수로 6번째·10번째였습니다. 점수 순으로 5개만 넘겼다면 근거를 놓쳤을 질문인데, AI가 15개를 읽고 6번·10번을 골라 정답을 썼습니다. 최종 시스템은 모든 질문이 이 3칸을 한 번씩 지나갑니다(AI 호출 2번, 5.7초). 초록 = 지나간 칸, 번호 = 지나간 순서.

칸	하는 일	쓴 기술
① 후보 15개 찾기	질문과 뜻이 비슷한 조각과 같은 단어가 있는 조각의 점수를 반반 섞어 상위 15개를 꺼냅니다	Hybrid 검색: `gemini-embedding-2` + Chroma, BM25 + 형태소 분석기 Kiwi, α 0.5
② AI가 5개 고르기	작은 AI가 15개를 읽고 답에 필요한 5개를 고릅니다	LLM rerank, `gemini-3.5-flash-lite`, 프롬프트 `rerank_v1`

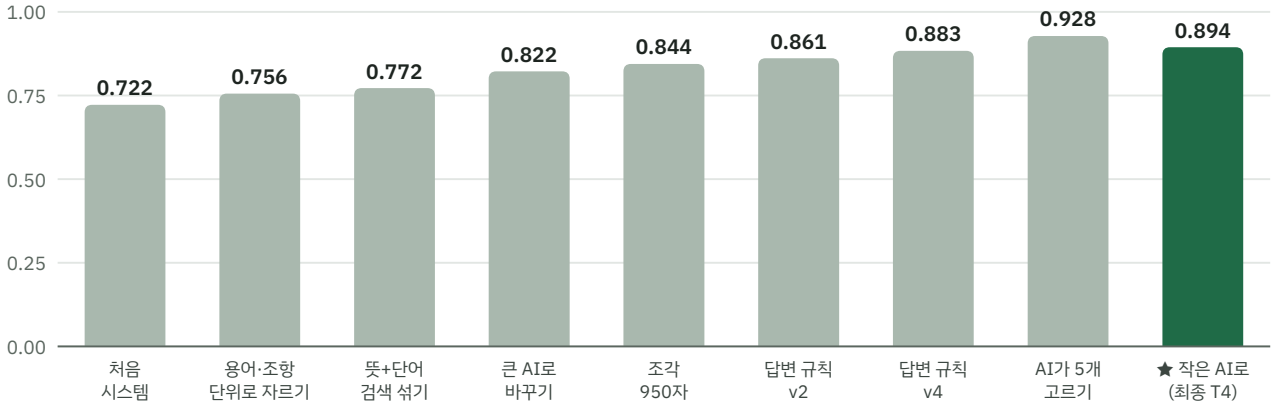
칸	하는 일	쓴 기술
③ 답 쓰기 + 출처	5개만 근거로 답합니다. 답함·보류·되묻기·거절 중 하나를 고르고, 출처 번호는 코드가 파일명·쪽으로 바꿉니다	같은 AI, 답변 규칙 `answer_v4`, 정해진 형식(JSON) 출력

미리 한 번 해 두는 일 (준비)



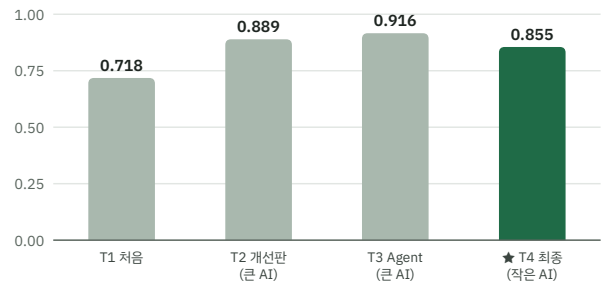
PDF 490쪽에서 글자를 뽑고, 표·그래프가 있는 190쪽은 AI(`gemini-3.8-flash`)가 그림을 글로 풀어 덧붙였습니다. 용어집은 용어 하나, 약관은 조항 하나를 한 조각으로, 나머지는 950자씩(119자 겹침) 잘랐습니다.

T4 최종 점수가 오른 과정 (연습 문제 90개)



설정은 모두 연습 문제로만 골랐습니다. 같은 설정을 다시 돌려도 90문항 중 약 14문항이 바뀌므로 ±0.03 안의 차이는 운의 범위입니다. 그 범위를 확실히 넘은 건 "AI가 5개 고르기"(0.883 → 0.928)였습니다. 마지막 막대는 같은 구조에서 AI만 작은 것으로 바꾼 최종 시스템입니다.

T4 최종 최종 시험 결과 (131문항: 제공 90 + 직접 만든 41)



정답 점수 (0~1). 초록 막대가 최종 시스템입니다.

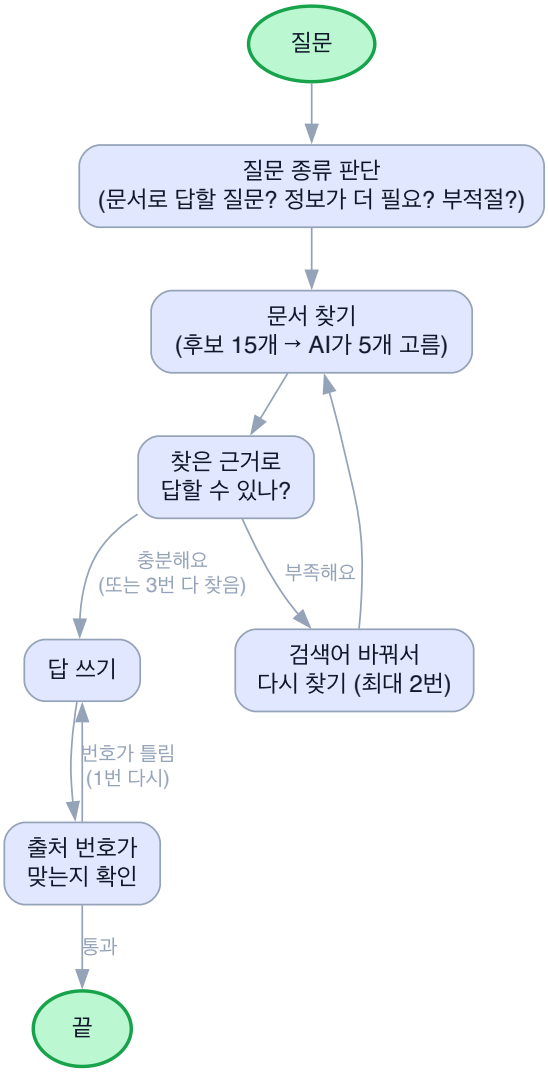
시스템	점수	질문당 비용	평균 / 느린 10%
T1 처음	0.718	0.0012달러	1.6 / 1.9초
T2 개선판 (큰 AI)	0.889	0.0090달러	5.4 / 6.9초
T3 Agent (큰 AI)	0.916	0.0131달러	9.4 / 16.5초
★ T4 최종 (작은 AI)	**0.855**	**0.0036달러**	**2.8 / 3.3초**

- T1 → T2: +0.172, 운의 범위 밖(확실한 개선)
- T2 → T4: −0.034, 운의 범위 안. 비용 0.4배, 속도 2배
- T2 → T3: +0.027, 운의 범위 안. 비용 1.5배

T3 Agent 비교: 기본 RAG 대 Agent

과제가 요구한 비교입니다. T2(기본 RAG, 3칸)에 **스스로 판단하는 칸**을 더해 T3를 만들었습니다. 찾기와 답 쓰기는 T2와 똑같고, 다른 것은 그래프뿐입니다.

T3 Agent의 구조 (비교용, 최종 아님)



끝나는 조건: 다시 찾기 최대 2번(총 3번 찾기), 출처 다시 쓰기 최대 1번.

칸	하는 일	쓴 기술
질문 종류 판단	문서로 답할 질문 / 내 정보가 더 필요 / 부적절한 요청 / 규칙을 어기라는 지시 중 하나로 봅니다	LLM 라우터 (수업 15번)
찾은 근거로 답할 수 있나?	찾은 5개로 답이 되는지 AI가 판단하고, 부족하면 무엇이 부족한지 적습니다	문서 평가 (수업 23번)
검색어 바꿔 다시 찾기	부족한 점을 보고 검색어를 새로 써서 다시 찾습니다. 새 조각은 앞의 것에 더합니다(최대 10개)	질문 재작성 + 재검색 (수업 23번)
출처 번호 확인	출처 번호가 실제로 찾은 조각을 가리키는지 코드로 확인하고, 틀리면 1번 다시 씁니다	코드 검사 (수업 10번)

칸	하는 일	쓴 기술
전체 흐름	칸과 화살표, 갈림길, 반복 횟수 제한	LangGraph StateGraph (수업 11·23번)

결과: 연습 문제 0.939 대 T2 0.928, 시험 0.916 대 0.889. 세 번 다 Agent가 조금 앞섰지만 매번 운의 범위 안이었고, 비용은 1.3~1.5배였습니다. 검색이 이미 거의 다 맞아서(정답 쪽을 찾는 비율 0.99) 다시 찾기가 90문항 중 3~9문항에서만 일어났습니다. 그래서 최종으로는 쓰지 않았습니다.

Agent v2 해 봤지만 효과가 없던 것

Agent v2 (시험 뒤 추가 실험, 버림): T3에 "답 검사" 칸을 더했습니다. 다른 AI가 답 초안에서 빠진 내용을 찾고, 있으면 1번 고쳐 쓰게 했습니다. 질문 종류 판단 결과도 답 쓰는 칸에 넘겼습니다.

결과: 연습 문제 0.928로 T2와 같았습니다. 검사 칸이 90개 중 3개만 지적했고, 겨냥한 "한 가지를 빠뜨린 답" 10개는 하나도 잡지 못했습니다. 비용만 1.5배라서 쓰지 않았습니다.

그 밖에 효과가 없던 것	결과
조각 크기만 바꾸기 (400~1,200자)	모두 운의 범위 안. 크기보다 어디서 자르느냐(용어·조항 단위)가 중요했습니다
단어 검색(BM25)만 쓰기	용어 질문에서도 근거를 찾는 비율이 오히려 낮았습니다 (0.80 대 뜻 검색 0.96)
찾는 개수 3개 / 8개	3개는 근거를 놓치고, 8개는 글이 너무 길어져 5개를 유지했습니다

배운 점

- **점수를 올린 건 "찾는 방법"을 고친 일**이었습니다. 용어·조항 단위로 자르기(정답 쪽을 찾는 비율 0.88 → 0.96), AI가 다시 고르기(0.883 → 0.928).
- **Agent는 남은 실패에 맞춰 설계해야 합니다.** 검색을 먼저 다 고친 뒤에는 Agent가 겨냥한 "못 찾음" 실패가 거의 사라져 있었습니다.
- **작은 차이는 운일 수 있습니다.** 같은 설정도 다시 돌리면 90문항 중 14문항이 바뀌어, 그보다 작은 차이는 개선이라고 하지 않았습니다.

자세한 수치와 근거: `submission/EVALUATION.md`, 진행 기록 `submission/PROCESS.md`, 회고 `submission/RETROSPECTIVE.md`.