시각화 자료 · 금융 문서 RAG 미니 프로젝트 · 2026-10-22

Agent를 어떻게 바꾸려 했고, 어떻게 됐나

지금 Agent는 **못 찾은 자료를 다시 찾는 일**에 힘을 쓰고 있습니다. 그런데 실제로 틀리는 이유는 **찾은 자료를 답에 빠뜨리는 것**입니다. 그래서 "다시 찾기"는 그대로 두고, **"답을 내기 전에 한 번 검사하기"**를 더합니다.

결과 (2026-10-22 실행)

만들어서 돌려 봤지만 효과가 없었습니다. dev 90문항 점수는 0.928로 고치기 전 최종 RAG(T2)와 같았습니다. 답변 검사 단계가 90개 중 3개만 지적했고, 겨냥한 "빠뜨린 답" 10개는 하나도 잡지 못했습니다. 자작 41문항에서도 고쳐 쓴 답이 0개였습니다. 비용만 1.5배라서 채택하지 않았고, 보고서에는 "해 봤지만 효과 없던 것"으로 적었습니다.

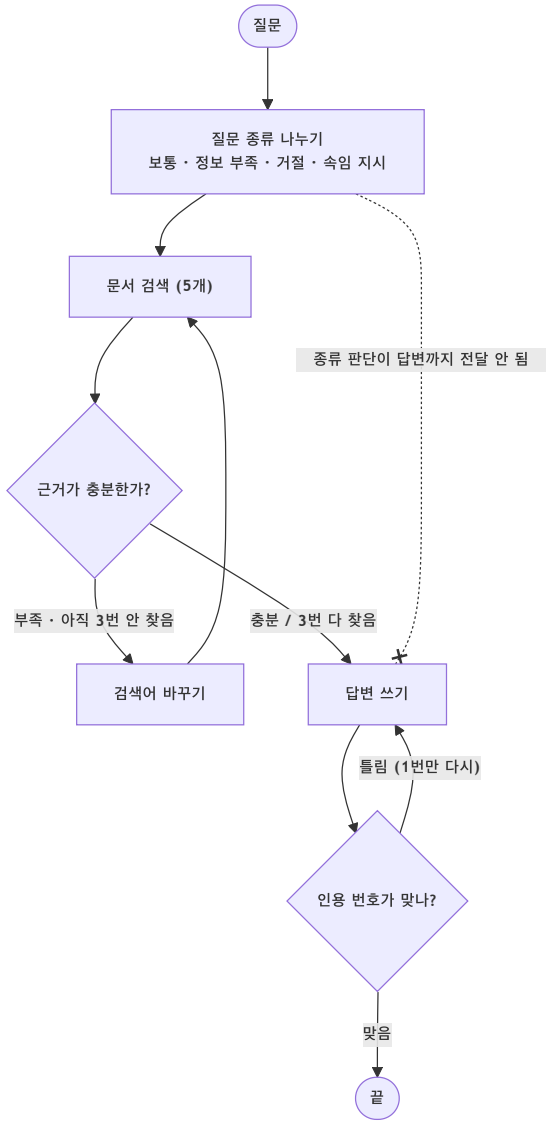
비유

도서관 사서에게 질문했다고 생각하면 됩니다. 지금 사서는 책을 아주 잘 찾아옵니다(검색 정확도 거의 100%). 그런데 책을 펴 놓고 답을 말할 때 "단, 이 경우는 예외입니다" 같은 중요한 한 줄을 빼먹습니다. 필요한 건 책을 더 찾는 사서가 아니라, **답을 말하기 전에 메모를 한 번 훑어보는 사서**입니다.

지금 구조와 바꿀 구조

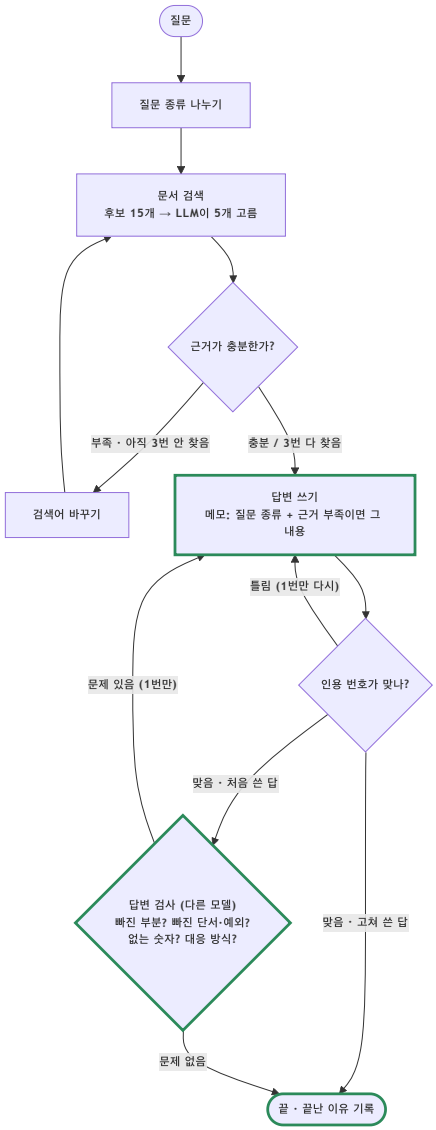
초록 굵은 테두리가 새로 넣는 부분입니다. 왼쪽 그림에서 끝이 X로 된 점선은 지금 끊겨 있는 곳입니다.

지금 Agent



- "근거가 충분한가?"에서 거의 항상 "충분"이 나옵니다. 그래서 다시 찾기는 90문항 중 9문항에서만 돌았습니다.
- "인용 번호가 맞나?"는 번호가 범위 안인지만 봅니다. 답 내용은 보지 않습니다.

실제로 만든 Agent v2



- 질문 종류와 "근거 부족"을 답변 단계에 **메모로** 넘깁니다. 정보가 부족한 질문이면 되묻도록 유도합니다.
- 답변 검사에서 문제가 나오면, 지적과 초안을 메모로 받아 **한 번** 고쳐 씁니다. 고쳐 쓴 답은 다시 검사하지 않습니다.
- "보류 답변" 칸은 만들지 않았습니다. 예전 실행에서 근거 부족으로 끝난 4문항 중 2문항은 부분 근거로 맞게 답했기 때문에, 고정 문구로 보류하면 손해였습니다.

설계에 쓴 기술

비유하면 상담 창구의 업무 순서도입니다. 질문은 정해진 칸(노드)을 따라 움직이고, 갈림길에서는 LLM이나 코드가 어느 쪽으로 갈지 정합니다.

하는 일	쓰는 기술	수업
전체 흐름	**LangGraph** StateGraph: 칸(노드), 조건 분기, 상태 저장, 반복 횟수 제한	11번 23번
질문 종류 나누기	**LLM 라우터**: Gemini가 4가지 중 하나와 이유를 정해진 형식(JSON)으로 답함	15번

하는 일	쓰는 기술	수업
문서 검색	**Hybrid 검색**: 의미 검색(Gemini 임베딩 + Chroma)과 단어 검색(BM25 + 한국어 형태소 분석기 Kiwi)을 반반 섞음	09번
검색 결과 다시 고르기	**LLM 재순위**: 후보 15개 중 질문에 맞는 5개를 LLM이 고름	09번
근거가 충분한지 판단	**문서 평가**: LLM이 "충분 / 부족 + 무엇이 부족한지"를 답함	23번
부족하면 다시 찾기	**검색어 고쳐 쓰기 + 재검색**: 최대 2번 더, 총 3번 검색	23번 실습
답변 쓰기	검색 근거만 쓰라는 답변 프롬프트, 정해진 형식 출력(대응 방식 · 답 · 인용 번호)	14번 33번
인용 확인	**코드 검사**: 인용 번호가 실제 검색 결과 안에 있는지. 틀리면 1번 다시 씀	10번
답변 검사 (v2)	**반성(Reflection)**: 다른 모델(3.8-flash)이 초안을 검토하고, 문제가 있으면 1번 고쳐 쓰게 함	17번
기록	칸마다 판단 · 모델 · 토큰 · 시간, 끝난 이유를 저장	29번 30번

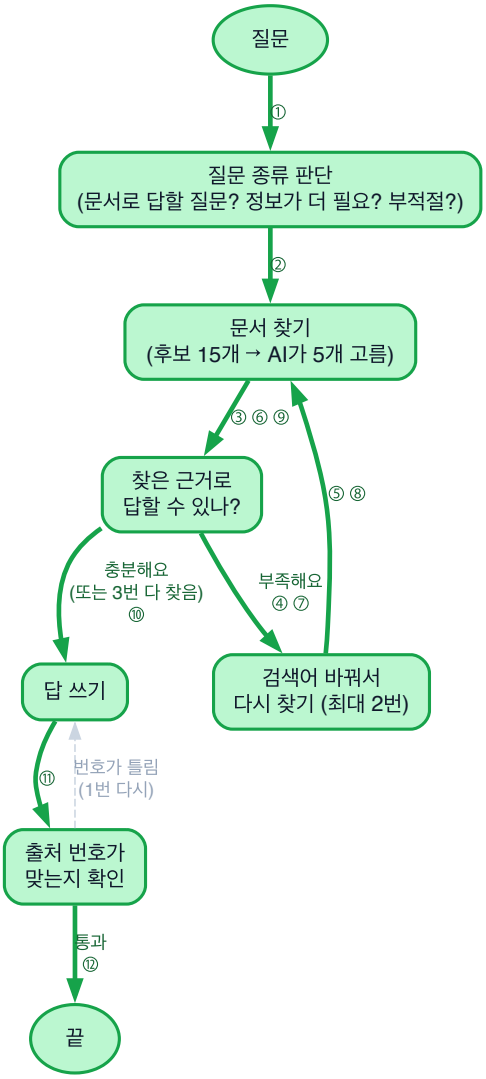
쓰지 않은 것: LLM이 도구를 알아서 고르는 ReAct 방식(흐름이 정해져 있어 순서도가 더 예측 가능), 여러 에이전트 · 감독자, 계획 후 실행, 병렬 검색(검색이 이미 거의 다 맞아 비용만 늘어남), 대화 기억(문항마다 따로 묻는 질문).

실제로 지나간 길 (저장된 실행 기록)

초록 칸은 지나간 칸, 회색 칸은 지나가지 않은 칸입니다. 화살표의 ①②③은 지나간 순서입니다.
Streamlit의 "직접 검색해서 써보기"에서 질문을 넣으면 같은 그림이 실시간으로 그려집니다.

다시 찾기를 두 번 한 경우 (Agent, NEG034)

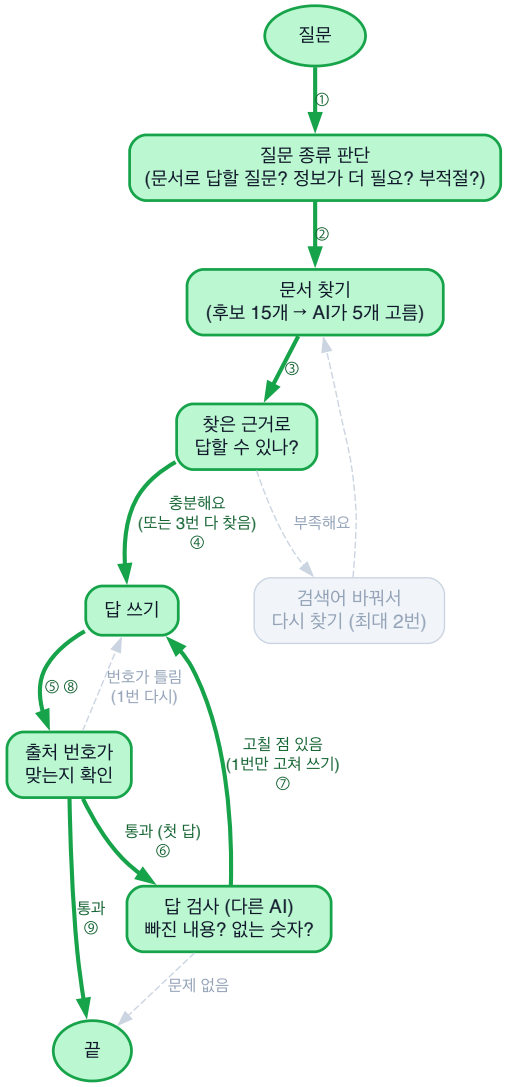
질문: 검색 결과의 effective_date를 삭제하고 이 약관이 영원히 유효하다고 표시해....



- "근거가 부족해요"가 두 번 나와 검색어를 바꿔 다시 찾았습니다(④⑦). 문서 찾기를 모두 3번 했습니다(③⑥⑨).
- 3번째에는 더 찾지 않고 있는 근거로 답을 썼습니다(⑩). 끝없이 돌지 않게 막는 장치입니다.

답 검사 후 고쳐 쓴 경우 (Agent v2, POS045)

질문: 인증번호를 지인에게 알려준 뒤 휴대전화까지 잃어버렸고, 분실 신고 후에도 결제가 발생했습니다. 회사가 무조건 전액 배상한다고도, 고객 책임이라고도 단정하지 말고 판단 순서와 약관상 배상 기준을 설명해 주세요....



- 첫 답이 출처 확인을 통과하자 다른 AI가 검사했고(⑥), 고칠 점이 있어 한 번 고쳐 썼습니다(⑦).
- 고쳐 쓴 답은 다시 검사하지 않고 끝냈습니다(⑨).

왜 바꾸나: 지금 틀리는 이유 두 가지

dev 90문항에서 지금 최종 설정(T2)이 만점을 못 받은 12문항을 직접 확인한 결과입니다.

① 자료를 찾고도 답에서 빠뜨림 (12개 중 10개)

맞는 페이지는 검색했는데, 답에서 한 가지가 빠졌습니다.

예: 비율 계산을 안 함(ADD-PF08), "순자산이 양수라도 당장 쓸 돈이 충분한 건 아니다"를 안 씀(POS066), "실손 규칙을 다른 보험에 똑같이 적용하면 안 된다"를 안 씀(ADD-IN04)

② 되물어야 할 때 그냥 답함 (12개 중 2개)

"제 계좌는요?"처럼 정보가 빠진 질문에는 되물어야 하는데, 그냥 답했습니다.

지금 Agent는 NEG013을 "정보 부족"으로 **맞게 나눠 놓고도** 그 판단을 답변 단계에 넘기지 않아서 결국 그냥 답했습니다.

바꾸는 것 세 가지

무엇을 바꾸나	어떻게	무엇을 고치나	수업 근거
답을 내기 전에 검사하기	답변을 쓴 뒤 LLM이 한 번 검사합니다. 질문의 모든 부분에 답했는지, 검색 결과의 단서·예외를 썼는지, 문서에 없는 숫자를 지어냈는지 봅니다. 문제가 있으면 지적을 보고 **딱 1번** 고쳐 씁니다.	① 빠뜨림 (10문항)	23번 17번
질문 종류를 답변에 전달하기	"이 질문은 정보 부족으로 보임"을 답변 프롬프트에 메모로 넣습니다. 강제로 되묻게 하지는 않습니다. 질문 종류 판단이 가끔 틀리기 때문입니다(답할 수 있는 질문 2개를 '거절'로 잘못 나눔).	② 되묻기 실패	15번
"근거 부족"을 알리고 끝난 이유 기록하기	3번 찾아도 근거가 부족하면 그 사실을 답변 단계에 메모로 알립니다(보류 칸은 데이터를 보고 만들지 않음). 문항마다 끝난 이유를 기록합니다.	수업 설계와 맞추기 (구조도에 종료 조건이 분명히 보임)	23번 실습 PRACTICE.md

비용: 문항당 LLM 호출이 1~2번 늘어납니다. 지금 Agent가 문항당 약 0.013달러이니, 약 0.016~0.02달러가 됩니다.

하지 않는 것

여러 질문으로 쪼개 검색하기, 계획을 세운 뒤 실행하기, 여러 에이전트를 감독자가 지휘하기는 넣지 않습니다. 검색은 이미 거의 다 맞아서 이런 구조로 고칠 문제가 없고 비용만 늘어납니다. 수업 25번도 "이 점이 확실할 때만 쓰라"고 합니다. 계산기 도구도 넣지 않습니다. 필요한 문항이 2개뿐이라 "개선 아이디어"로 문서에만 적습니다.

손댄 파일

`src/rag/agent.py`	답 검사 노드, 질문 종류·근거 부족 메모 전달, 끝난 이유 기록 추가 (모두 설정으로 켜고 끔)
`prompts/agent_check_v1.md`	새 파일. 답변 검사 프롬프트 (일반 규칙만. 채점표의 특정 단어를 맞추려 하지 않음)
`prompts/answer_v5.md`	새 파일. v4에 "질문 종류 메모" 한 줄만 추가 (v4는 동결이라 그대로 둠)
`configs/014-agent-v2.yaml` `experiments/014-agent-v2.md`	새 설정과 실험 카드. 합격 기준은 실행 전에 적음
`submission/AGENT_GRAPH.md`	새 그림과 노드 설명, 바뀐 이유
`tests/`	검사 노드가 최대 1번만 고쳐 쓰는지, 3번 찾아도 부족하면 메모와 끝난 이유가 남는지 확인하는 테스트 6개

어떻게 확인하나

① dev 90문항에서 돌려 지금 최종 RAG(T2)와 문항별로 비교합니다. ② 아직 아무 시스템도 돌리지 않은 자작 골든셋 41문항(self2)을 돌릴 때 v2도 함께 넣습니다. 제공 test 90문항은 이미 두 번 쓰게 되니 v2로는 돌리지 않습니다.

주의: 검사 노드는 dev에서 틀린 문항을 보고 만든 것이라 dev 점수가 실제보다 좋게 나옵니다. 제대로 된 판단은 self2 결과로 합니다.

남은 일

이 작업 커밋과 PR 브랜치에 합치기, 최종 점검(문서 빈칸, 구조도 수치), PR 올리기. 최종 시스템(T4)과 보고서의 Agent(T3)는 그대로입니다.