시각화 자료 · 금융 문서 RAG 미니 프로젝트 · 2026-10-22

금융 문서 질의응답 시스템

금융 PDF 23개를 검색해, 찾은 근거만 보고 한국어로 답하고 출처(파일·쪽)를 붙이는 시스템입니다.

최종 시스템은 T4입니다. 질문이 오면 ① 후보 15개를 찾고 ② 작은 AI가 5개를 고르고 ③ 그 5개만 보고 답합니다. Agent가 아니라 3칸짜리 RAG입니다.

시험 131문항 점수 **0.855** (처음 시스템 0.718) · 질문당 **0.0036달러** · 평균 **2.8초**. 큰 AI 판(T2, 0.889)보다 0.03 낮지만 운의 범위 안이고, 비용은 40%, 속도는 2배라서 골랐습니다.

이 자료에 나오는 이름	무엇인가	나오는 곳
T4 최종	**제출하는 시스템. 3칸 RAG, 작은 AI (`configs/013b-rerank-lite.yaml`)**	**구조 · 점수 과정 · 시험 결과**
T1 · T2	비교용. T1은 처음 만든 RAG, T2는 T4와 같은 구조에 큰 AI	시험 결과
T3 Agent	비교용. 과제의 "기본 RAG 대 Agent" 비교를 위해 T2에 판단하는 칸을 더한 것	기본 RAG 대 Agent
Agent v2	시험 뒤에 해 본 개선 시도. 효과가 없어 버림	해 봤지만 효과가 없던 것

T4 최종 최종 시스템의 구조

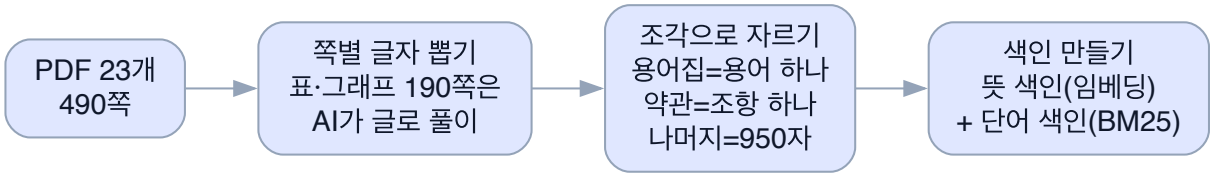
질문이 올 때마다 하는 일 (3칸)



질문당 AI 호출 2번, 문서 찾기 1번. 다시 찾거나 스스로 검사하는 칸은 없습니다.

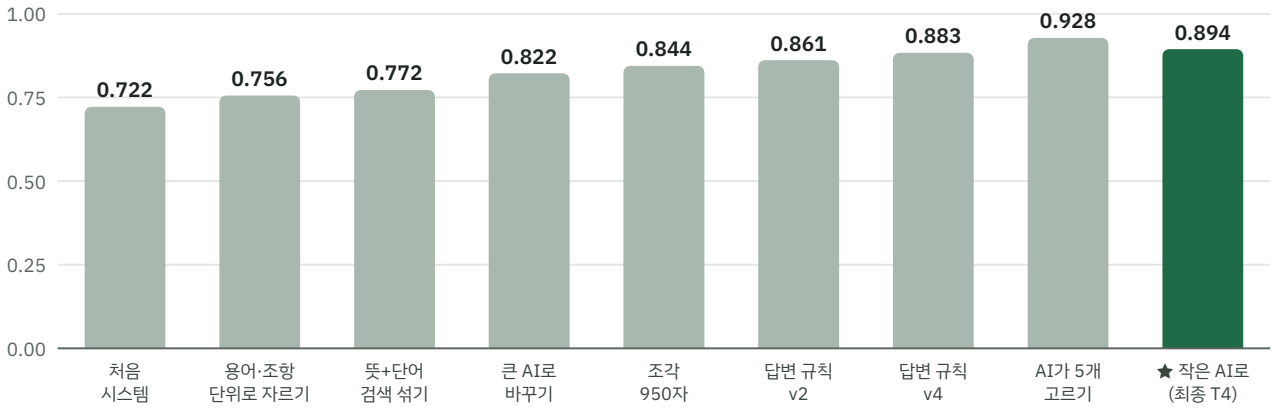
칸	하는 일	쓴 기술
① 후보 15개 찾기	질문과 뜻이 비슷한 조각과 같은 단어가 있는 조각의 점수를 반반 섞어 상위 15개를 꺼냅니다	Hybrid 검색: `gemini-embedding-2` + Chroma, BM25 + 형태소 분석기 Kiwi, α 0.5
② AI가 5개 고르기	작은 AI가 15개를 읽고 답에 필요한 5개를 고릅니다	LLM rerank, `gemini-3.5-flash-lite`, 프롬프트 `rerank_v1`
③ 답 쓰기 + 출처	5개만 근거로 답합니다. 답함·보류·되묻기·거절 중 하나를 고르고, 출처 번호는 코드가 파일명·쪽으로 바꿉니다	같은 AI, 답변 규칙 `answer_v4`, 정해진 형식(JSON) 출력

미리 한 번 해 두는 일 (준비)



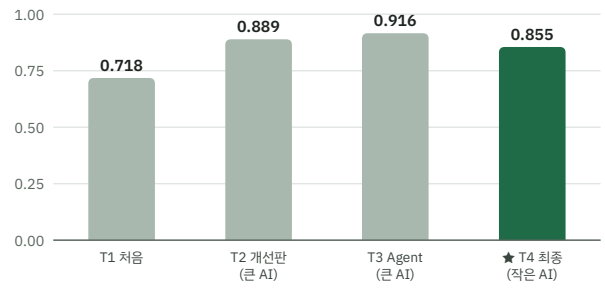
PDF 490쪽에서 글자를 뽑고, 표·그래프가 있는 190쪽은 AI(`gemini-3.8-flash`)가 그림을 글로 풀어 덧붙였습니다. 용어집은 용어 하나, 약관은 조항 하나를 한 조각으로, 나머지는 950자씩(119자 겹침) 잘랐습니다.

T4 최종 점수가 오른 과정 (연습 문제 90개)



설정은 모두 연습 문제로만 골랐습니다. 같은 설정을 다시 돌려도 90문항 중 약 14문항이 바뀌므로 ±0.03 안의 차이는 운의 범위입니다. 그 범위를 확실히 넘은 건 "AI가 5개 고르기"(0.883 → 0.928)였습니다. 마지막 막대는 같은 구조에서 AI만 작은 것으로 바꾼 최종 시스템입니다.

T4 최종 최종 시험 결과 (131문항: 제공 90 + 직접 만든 41)



정답 점수 (0~1). 초록 막대가 최종 시스템입니다.

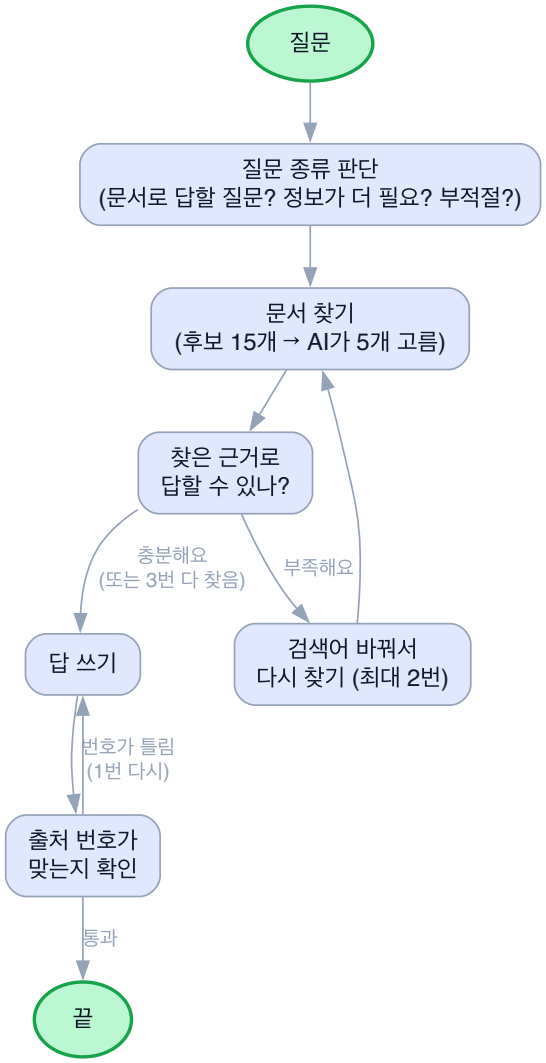
시스템	점수	질문당 비용	평균 / 느린 10%
T1 처음	0.718	0.0012달러	1.6 / 1.9초
T2 개선판 (큰 AI)	0.889	0.0090달러	5.4 / 6.9초
T3 Agent (큰 AI)	0.916	0.0131달러	9.4 / 16.5초
★ T4 최종 (작은 AI)	**0.855**	**0.0036달러**	**2.8 / 3.3초**

- T1 → T2: +0.172, 운의 범위 밖(확실한 개선)
- T2 → T4: −0.034, 운의 범위 안. 비용 0.4배, 속도 2배
- T2 → T3: +0.027, 운의 범위 안. 비용 1.5배

T3 Agent 비교: 기본 RAG 대 Agent

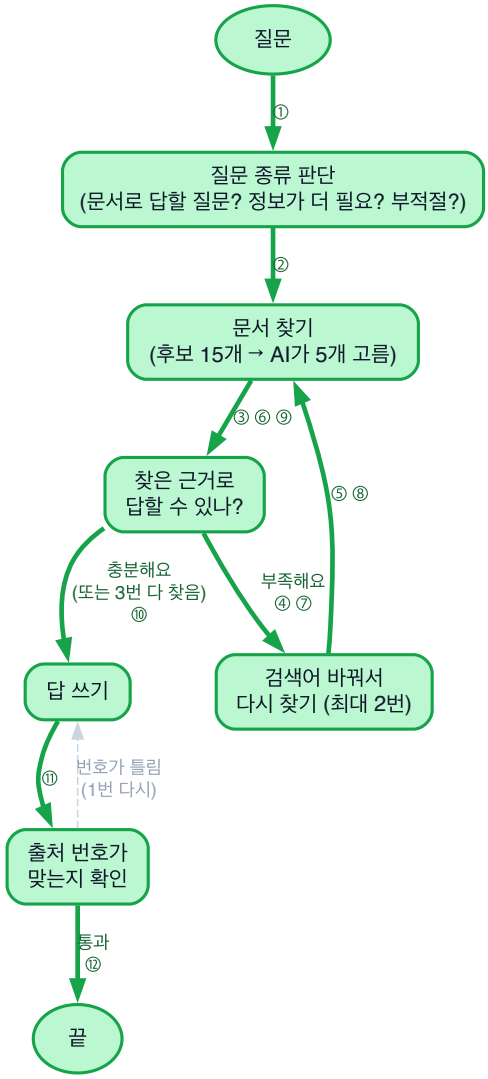
과제가 요구한 비교입니다. T2(기본 RAG, 3칸)에 **스스로 판단하는 칸**을 더해 T3를 만들었습니다. 찾기와 답 쓰기는 T2와 똑같고, 다른 것은 그래프뿐입니다.

T3 Agent의 구조



끝나는 조건: 다시 찾기 최대 2번(총 3번 찾기), 출처 다시 쓰기 최대 1번.

실제로 지나간 길 (연습 문제 NEG034)



"근거가 부족해요"가 두 번 나와 검색어를 바꿔 다시 찾았고(④⑦), 3번째 뒤에는 있는 근거로 답했습니다(⑩). 초록 = 지나간 칸, 번호 = 지나간 순서.

칸	하는 일	쓴 기술
질문 종류 판단	문서로 답할 질문 / 내 정보가 더 필요 / 부적절한 요청 / 규칙을 어기라는 지시 중 하나로 봅니다	LLM 라우터 (수업 15번)
찾은 근거로 답할 수 있나?	찾은 5개로 답이 되는지 AI가 판단하고, 부족하면 무엇이 부족한지 적습니다	문서 평가 (수업 23번)
검색어 바꿔 다시 찾기	부족한 점을 보고 검색어를 새로 써서 다시 찾습니다. 새 조각은 앞의 것에 더합니다(최대 10개)	질문 재작성 + 재검색 (수업 23번)

칸	하는 일	쓴 기술
출처 번호 확인	출처 번호가 실제로 찾은 조각을 가리키는지 코드로 확인하고, 틀리면 1번 다시 씁니다	코드 검사 (수업 10번)
전체 흐름	칸과 화살표, 갈림길, 반복 횟수 제한	LangGraph StateGraph (수업 11·23번)

결과: 연습 문제 0.939 대 T2 0.928, 시험 0.916 대 0.889. 세 번 다 Agent가 조금 앞섰지만 매번 운의 범위 안이었고, 비용은 1.3~1.5배였습니다. 검색이 이미 거의 다 맞아서(정답 쪽을 찾는 비율 0.99) 다시 찾기가 90문항 중 3~9문항에서만 일어났습니다. 그래서 최종으로는 쓰지 않았습니다.

Agent v2 해 봤지만 효과가 없던 것

Agent v2 (시험 뒤 추가 실험, 버림): T3에 "답 검사" 칸을 더했습니다. 다른 AI가 답 초안에서 빠진 내용을 찾고, 있으면 1번 고쳐 쓰게 했습니다. 질문 종류 판단 결과도 답 쓰는 칸에 넘겼습니다.

결과: 연습 문제 0.928로 T2와 같았습니다. 검사 칸이 90개 중 3개만 지적했고, 겨냥한 "한 가지를 빠뜨린 답" 10개는 하나도 잡지 못했습니다. 비용만 1.5배라서 쓰지 않았습니다.

그 밖에 효과가 없던 것	결과
조각 크기만 바꾸기 (400~1,200자)	모두 운의 범위 안. 크기보다 어디서 자르느냐(용어·조항 단위)가 중요했습니다
단어 검색(BM25)만 쓰기	용어 질문에서도 근거를 찾는 비율이 오히려 낮았습니다 (0.80 대 뜻 검색 0.96)
찾는 개수 3개 / 8개	3개는 근거를 놓치고, 8개는 글이 너무 길어져 5개를 유지했습니다

배운 점

- **점수를 올린 건 "찾는 방법"을 고친 일**이었습니다. 용어·조항 단위로 자르기(정답 쪽을 찾는 비율 0.88 → 0.96), AI가 다시 고르기(0.883 → 0.928).
- **Agent는 남은 실패에 맞춰 설계해야 합니다.** 검색을 먼저 다 고친 뒤에는 Agent가 겨냥한 "못 찾음" 실패가 거의 사라져 있었습니다.
- **작은 차이는 운일 수 있습니다.** 같은 설정도 다시 돌리면 90문항 중 14문항이 바뀌어, 그보다 작은 차이는 개선이라고 하지 않았습니다.

자세한 수치와 근거: `submission/EVALUATION.md`, 진행 기록 `submission/PROCESS.md`, 회고 `submission/RETROSPECTIVE.md`.